

Relatório de Extração e Transformação de Dados (Semana 2)

1. Problemas Detetados

- **OWID COVID-19:** Presença de registos com iso_code nulo ou com prefixos de agregados continentais/económicos, cuja inclusão duplicaria artificialmente a volumetria real dos países.
- **WHO Life Expectancy:** Registos duplicados para o mesmo ano/país devido à divisão de dados por género (*Male*, *Female* e *Both sexes*).
- **Kaggle Vacinação:** Elevada percentagem de valores omitidos (NaN) nas métricas cumulativas temporais nos dias em que não existiram reportes oficiais por parte dos países.

2. Decisões Tomadas e Regras de Limpeza (Camada Silver)

- **Filtragem de Escopo:** Eliminação estrita de todas as linhas com códigos OWID_* ou sem identificador geográfico válido.
- **Normalização WHO:** Filtragem exclusiva pelo indicador combinado SEX_BTSEX (Ambos os sexos) de nível país, seguida da remoção de duplicados na chave composta [iso_code, year].
- **Imputação Temporal:** Aplicação de Forward Fill agrupado por país no dataset de vacinação para propagar o último valor cumulativo conhecido. Valores nulos residuais sem histórico anterior foram convertidos para 0.
- **Engenharia de Features:** Criação do indicador numérico num_vaccine_types a partir da contagem de vacinas contidas na string de texto original.

3. Integração e Engenharia de Métricas (Camada Gold)

- **Harmonização de Granularidade:** Agregação dos dados diários para a escala Anual por País. Aplicou-se a operação de Soma para variáveis de fluxo (new_cases, new_deaths) e a operação de Máximo para estados cumulativos de vacinação.
- **Estratégia de Joins Relacionais:** * Inner Join entre OWID e WHO: Justifica-se porque países sem indicadores estruturais de saúde base não servem o propósito de correlação do projeto.
 - Left Join com Vacinação: Garante que nações que não iniciaram ou não reportaram campanhas de vacinação não sejam erradicadas da base histórica.

- **Métricas Normalizadas:** Criação dos rácios `death_rate_per_100k` (Mortalidade por 100 mil habitantes) e `vaccination_rate` (% da população vacinada) para anular o viés demográfico de países com populações muito díspares.

4. Indicadores de Validação (Data Quality)

- **Integridade:** 0% de códigos ISO nulos ou inválidos nas tabelas finais.
- **Consistência:** 0 registos com novos casos ou óbitos negativos pós-processamento.
- **Validação de Domínio:** Todos os valores de expectativa de vida validados no intervalo biológico realista de [30 - 100] anos.